基于 OpenHarmony 操作系统构建离线多模态大模型 APP

参赛队伍: 炸薯丸

队伍成员: 查贝斯、索子骁、王子宁

学校: 中国科学技术大学

指导老师: 李永坤、徐伟

目录

01. 赛题调研
Contest Research

02. 项目研发
Research & Development

03. 成果展示
Presentation

04. 总结展望
Summary & Outlook

第一章

赛题调研

赛题调研

Contest Research

OpenHarmony

下一代智能终端设备操作系统

OpenHarmony 是一款面向全场景的开源分布式操作系统，可以部署在不同体量的硬件设备上。其提供高效安全的应用能力和开发环境，为多模态大模型的本地化部署提供了完整的系统能力集。

MNN

Llama

模型推理框架

经过调研和初步试验，本地化大模型推理使用 Llama.cpp 和 MNN 两种框架实现。前者功能灵活但文档欠缺，后者模块化程度更高但缺乏自定义优化条件。

HarmonyOS NEXT

隐私安全 & 系统能力

本地化大模型部署的核心优势在于数据的本地化存储与推理终端隔离性，同时，本地大模型与系统对接，可以更好地理解用户需求，帮助用户实现任务与功能管理。

任务分析

Contest Research

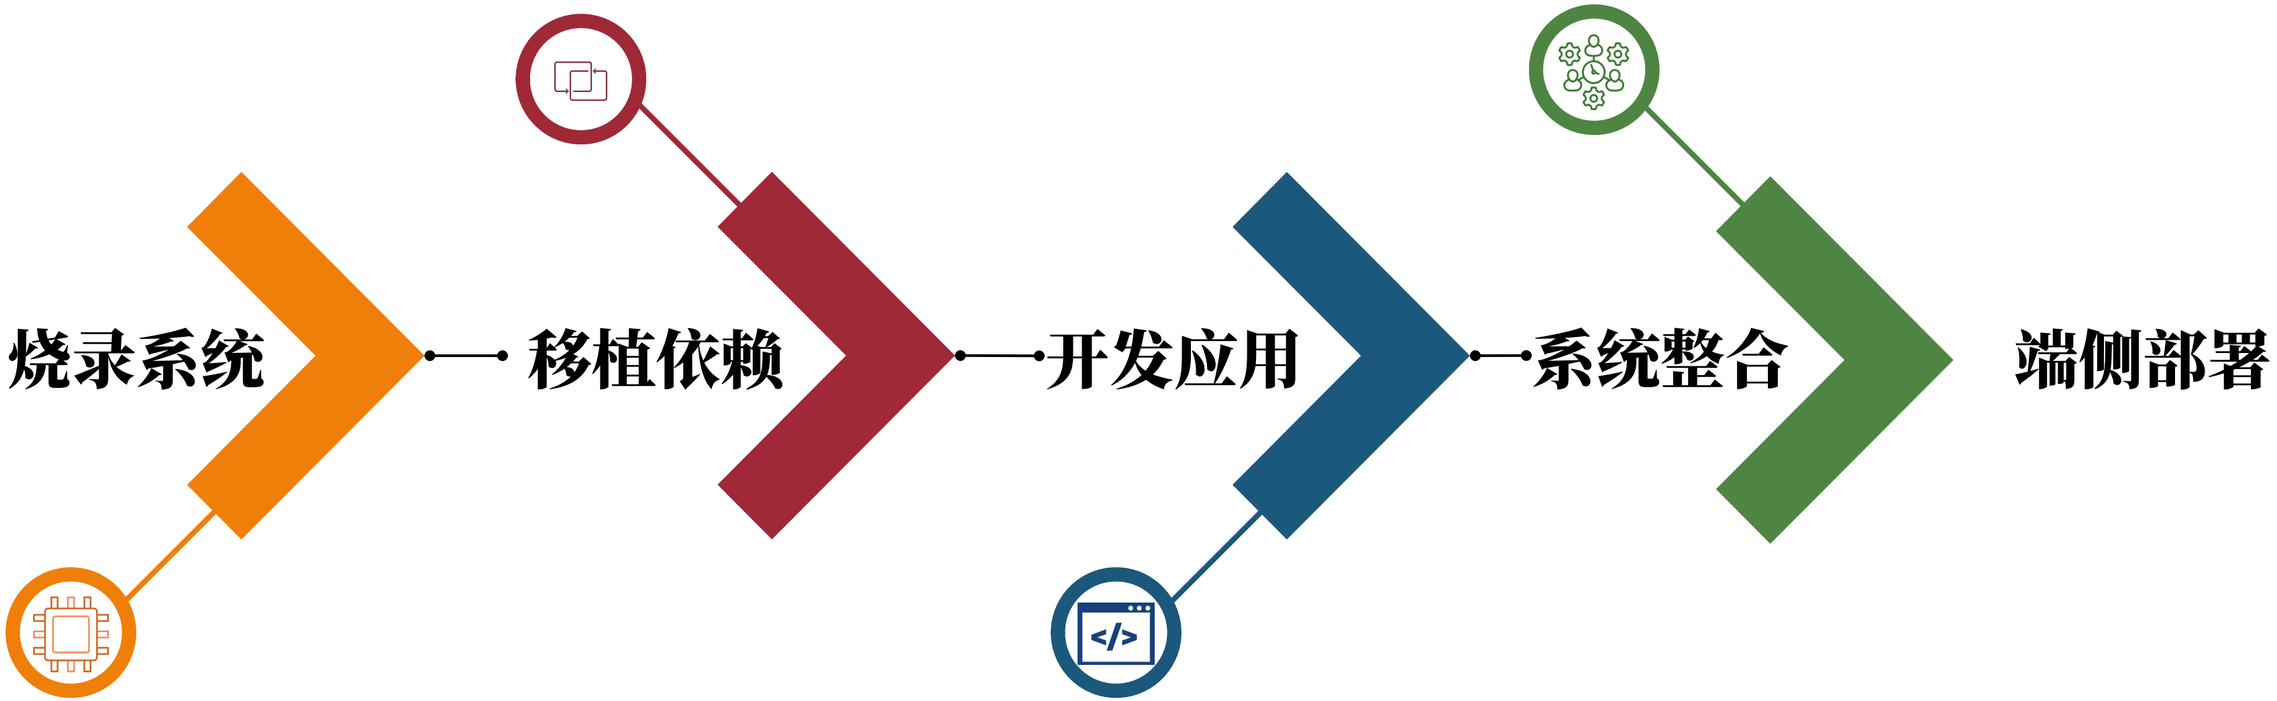

第二章

项目研发

软件架构

采用MVVM（Model-View-ViewModel）架构模式来组织应用， 通过model (模型)、view（视图）和 viewmodel（视图模型）之间的分离来 实现更好的代码组织和可维护性。

后端设计

model 层负责加载大模型权重文件，基于前端输入数据进行推理计算， 并将最终结果返回前端。

中间层

viewmodel 层模型推理模块基于OpenHarmonyNDK开发，采用C++ 实现；数据库模块使用鸿蒙关系型数据库实现数据的持久化存储。

UI 设计

整体采取简约风格，以白色为主、浅色为辅，突出关键元素。包含安全添加模型、历史会话隐私存储、个性化prompt 等诸多能力

Llama.cpp & MNN

Contest Research

llama.cpp 采用 c++ 进行编写。为了向OpenHarmony移植相关的库，我们进行了如下工作：

1. 获取 llama.cpp 的源代码
2. 从 openharmony 的官网中获取交叉编译工具链
3. 使用交叉编译工具链对llama.cpp进行编译，获得适用于openharmony 的动态链接库
4. 将编译好的动态链接库放置在openharmony 的 lib 目录下，并修改 CMakeLists.txt 文件，添加对 llama.cpp 的依赖

MNN 本身支持 OpenHarmony，对于后端也提供 GPU 硬件支持，但失去了较多的灵活性。
MNN 同时支持使用 GPU 处理多模态大模型（包括图片解析与音频翻译），整合 OpenCV 与 OpenCL，充分利用硬件计算资源。
我们做了如下工作：

1.根据MNN官方文档，对MNN源码进行编译，获得 对应.so 依赖库。

2.编写类似于Llama.cpp地大模型推理函数，整合依赖文件，执行大模型推理。

第三章

成果展示

成果展示

Presentation

侧边栏历史对话列表

- 保存了用户的历史对话记录
- 支持自行删除对话记录、编辑对话标题

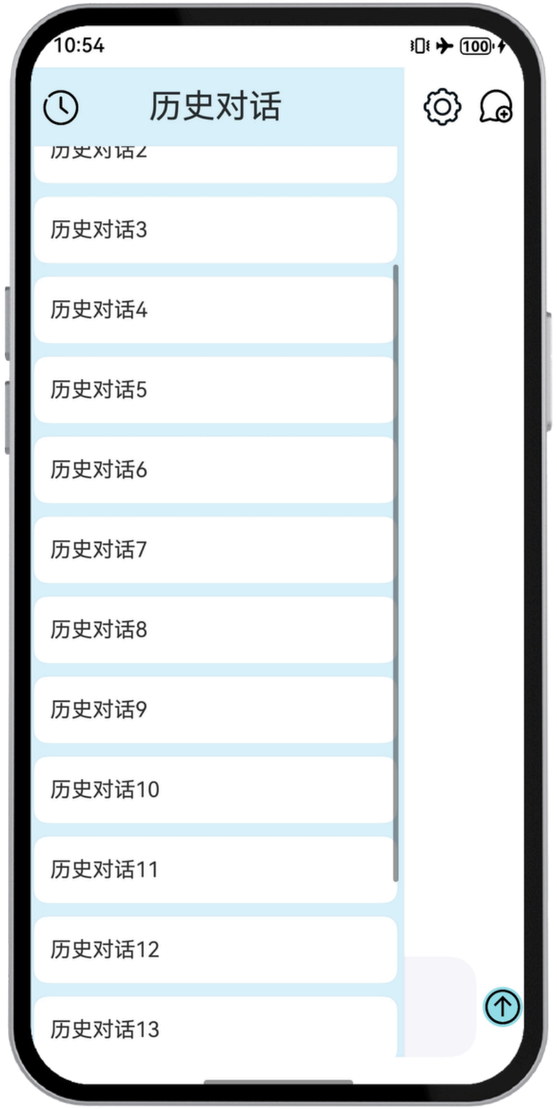

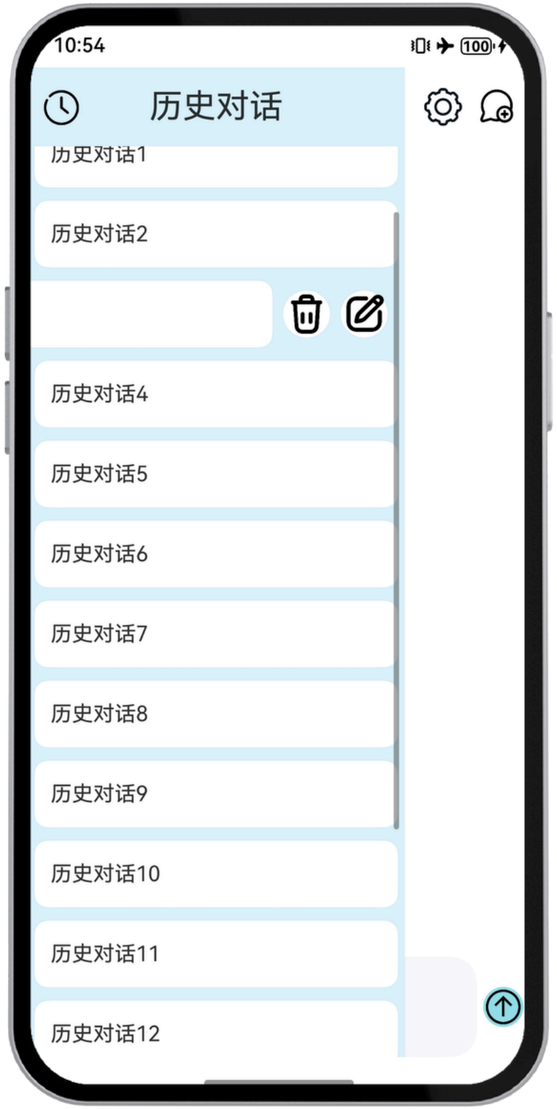

成果展示

Presentation

添加新模型

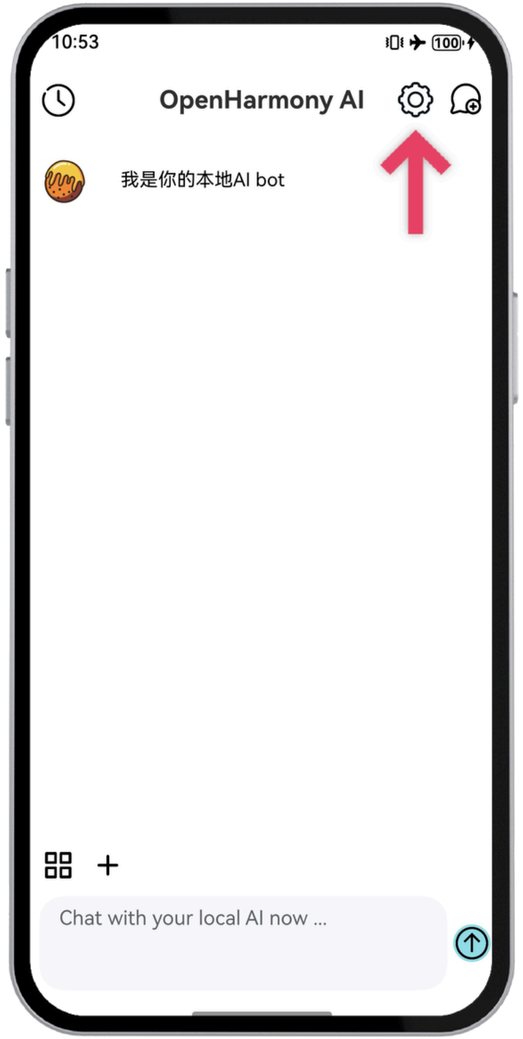

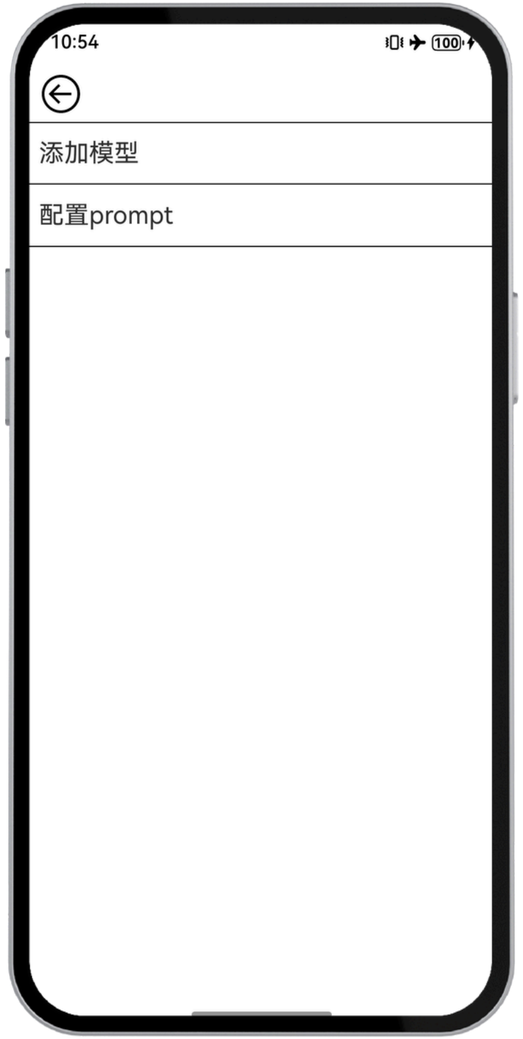

成果展示

Presentation

支持丰富的markdown渲染

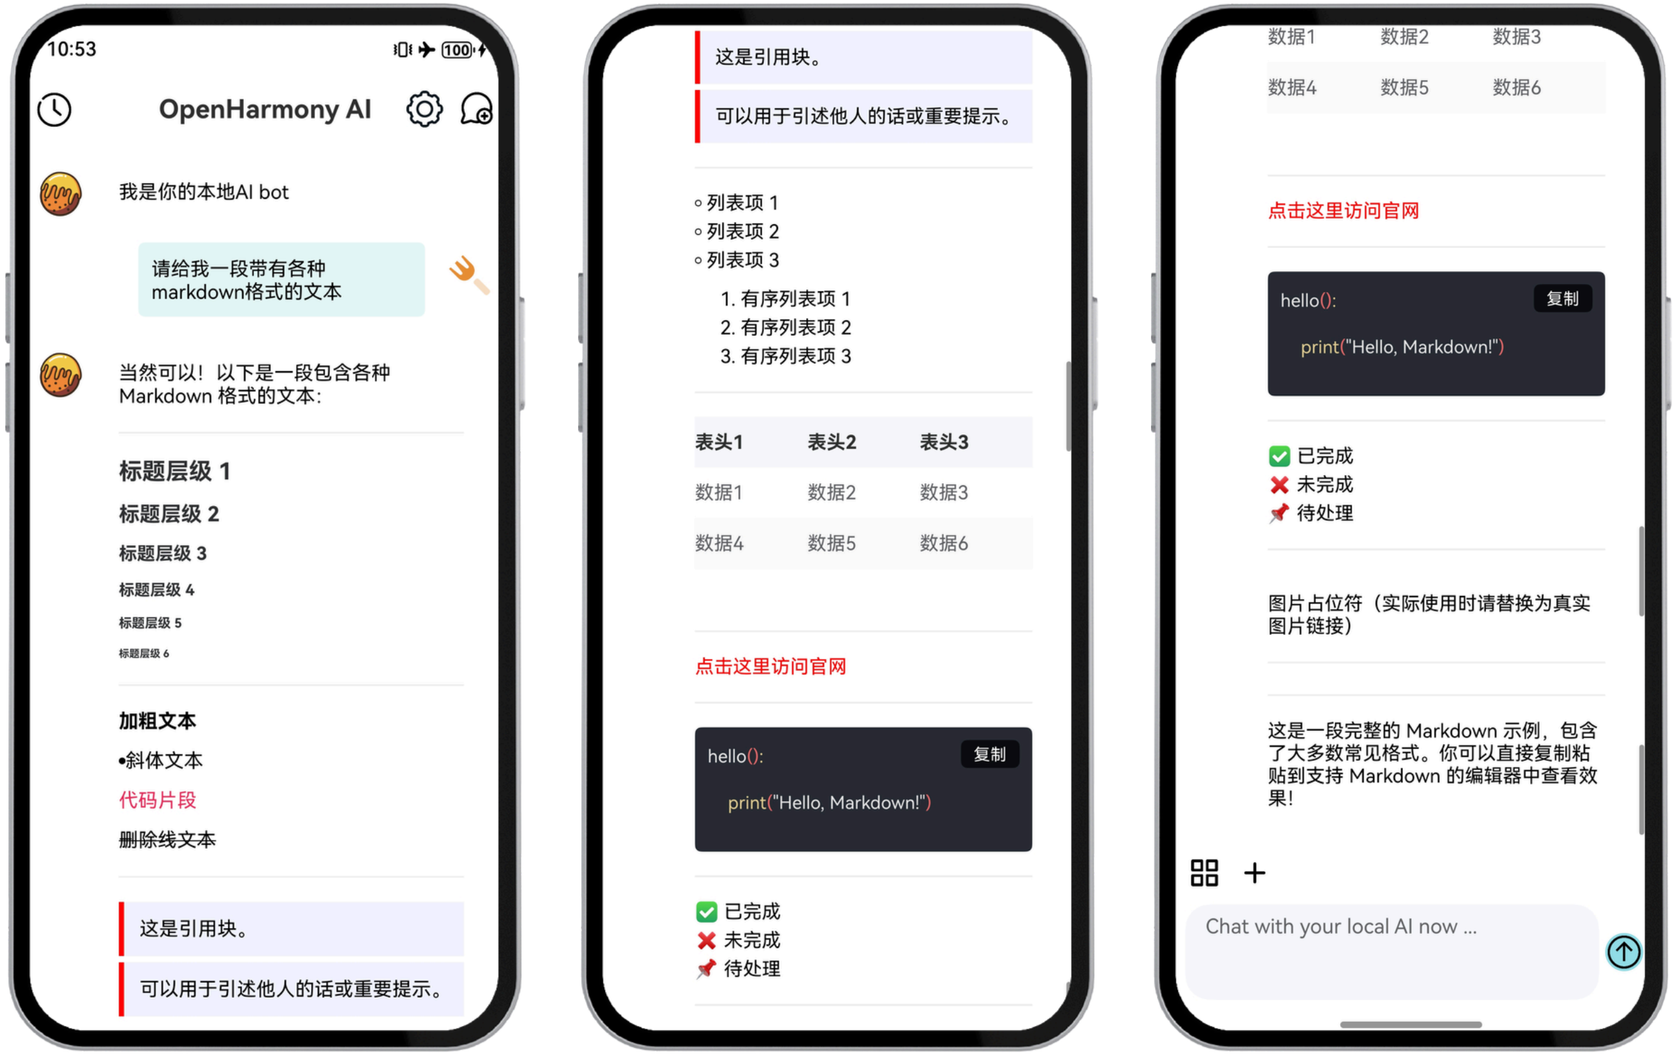

成果展示

Presentation

完整操作演示

具体性能数据:

表 2: 大模型端侧推理性能测试

model	modelSize	backend	threads	precision	test	t/s
Qwen-VL-Chat-MNN	3.72 GiB	CPU	4	Low	pp512	15.11 ± 3.29
Qwen-VL-Chat-MNN	3.72 GiB	CPU	4	Low	tg128	3.04 ± 0.00

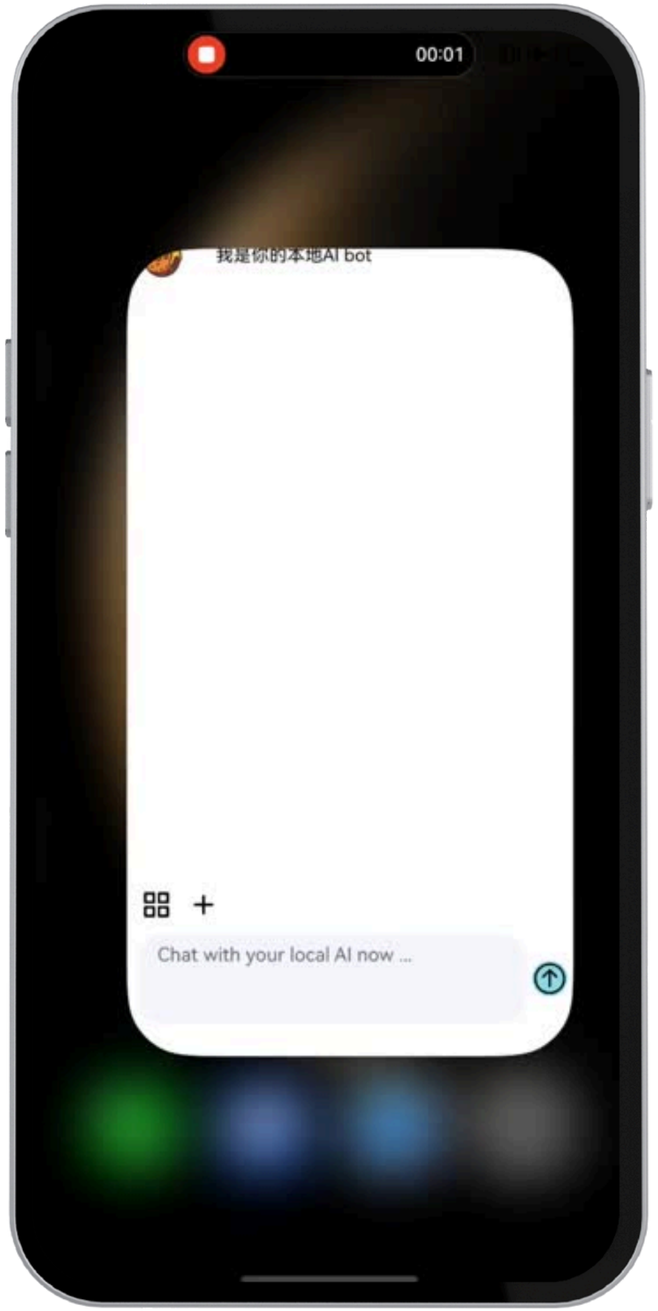

注：方便展示起见，视频经过简单剪辑

多模态推理演示

具体性能数据:

表 2: 大模型端侧推理性能测试

model	modelSize	backend	threads	precision	test	t/s
Qwen-VL-Chat-MNN	3.72 GiB	CPU	4	Low	pp512	15.11 ± 3.29
Qwen-VL-Chat-MNN	3.72 GiB	CPU	4	Low	tg128	3.04 ± 0.00

注：方便展示起见，视频经过简单剪辑

系统调用

通过分析理解用户意图，拉起相关的手机应用，提供综合的能力服务。

注：方便展示起见，视频经过简单剪辑

第四章

总结展望

总结

在经过赛题调研、分步项目研发、功能权衡一系列过程后，我们成功地完成了本次赛题的任务——基于OpenHarmony操作系统构建离线多模态大模型APP，并做出了一些拓展性的成果！

这一路走来，我们：

- 克服了各种困难，如：移植库文件缺失，第三方库接口不足、陌生的鸿蒙开发API等。
- 学习并实践了很多操作系统的知识，如：多线程调度、响应延迟优化等。
- 从赛题中得到了各个方面的启发，如：意识到用户的安全隐私对端侧AI推理的需求、应用开发效率与功能的权衡等。

展望

模型推理方面

- 更快的推理速度
  - 目前 llama.cpp 和 MNN 两个框架的推理速度可初步满足用户需求。未来，可以将model backend 移植到 GPU 或者 NPU 上，以进一步提高推理速度。
- 更丰富的模型
  - 在终端设备的算力条件下，可以部署更多的模型，如“文生图”、ai语音聊天等

应用开发方面

- 更完善的数据库
  - 完善各类后端处理，达到市面主流ai对话app的水平，如：对ai回答的某些部分继续追问、聊天分组、ai自动生成聊天标题
- 更成熟的系统调用
  - 充分利用 OpenHarmony 的特性，实现各种实用的功能：
    - 在打包参数后拉起应用的相关功能页，如：拉起花瓣地图，自动填入起、终点，直接开始规划路线
    - 分布式能力、“一多”能力：各端均可部署app，在手表上进行ai聊天，推理在手机或平板上进行
    - ……

致谢

感谢学校和举办方对比赛的大力支持

感谢 李永坤、徐伟 老师的辅导和 郑森文 老师对赛题的解读与提点

感谢华中科技大学提供的校园美食和湖畔美景

欢迎各位评委提问

参赛队伍: 炸薯丸

队伍成员: 查贝斯、索子骁、王子宁

学校: 中国科学技术大学

指导老师: 李永坤、徐伟

Thank You

参赛队伍: 炸薯丸

队伍成员: 查贝斯、索子骁、王子宁

学校: 中国科学技术大学

指导老师: 李永坤、徐伟